IE221 - BÀI THỰC HÀNH 7
PHÂN TÍCH DỮ LIỆU TỔNG HỢP

Ngày 23 tháng 12 năm 2025

Mục lục

1. BỘ DỮ LIỆU CUNG CẤP 2

2. CÂU HỎI 2

2.1 Câu 1: Chuẩn bị và khảo sát dữ liệu cơ bản . . . 2
2.2 Câu 2: Làm sạch và biến đổi dữ liệu . . . 3
2.3 Câu 3: Phân tích thống kê về giá . . . 3
2.4 Câu 4: Phân tích sản phẩm . . . 4
2.5 Câu 5: Phân tích về đánh giá sản phẩm . . . 4
2.6 Câu 6: Phân tích người dùng và review . . . 5
2.7 Câu 7: Trực quan hóa dữ liệu . . . 5
2.8 Câu 8: Khám phá dữ liệu văn bản . . . 5
2.9 Câu 9*: Tổng hợp phân tích . . . 6
2.10 Câu 10*: Tạo dashboard tổng hợp kết quả . . . 6

1. BỘ DỮ LIỆU CUNG CẤP

Amazon Sales Dataset là một bộ dữ liệu chứa thông tin chi tiết về 1000+ sản phẩm từ trang web chính thức của Amazon, bao gồm: Giá cả (giá gốc và giá khuyến mãi), Đánh giá sản phẩm (rating và số lượt đánh giá), Bình luận của người dùng (reviews), Thông tin danh mục sản phẩm, và Dữ liệu người dùng.

Thuộc tính (Features):

- product_id: Product ID - Mã định danh duy nhất cho mỗi sản phẩm trên Amazon
- product_name: Name of the Product - Tên đầy đủ của sản phẩm
- category: Category of the Product - Danh mục của sản phẩm
- discounted_price: Discounted Price of the Product - Giá khuyến mãi của sản phẩm tính bằng Rupee
- actual_price: Actual Price of the Product - Giá gốc của sản phẩm tính bằng Rupee
- discount_percentage: Percentage of Discount for the Product - Phần trăm chiết khấu so với giá gốc (%)
- rating: Rating of the Product - Điểm đánh giá trung bình của sản phẩm
- rating_count: Number of people who voted for the Amazon rating - Số lượng người dùng đã đánh giá sản phẩm
- about_product: Description about the Product - Mô tả chi tiết về sản phẩm (từ nhà sản xuất)
- user_id: ID of the user who wrote review for the Product - Mã định danh duy nhất của người dùng viết review
- user_name: Name of the user who wrote review for the Product - Tên người dùng (hiển thị công khai trên Amazon)
- review_id: ID of the user review - Mã định danh duy nhất cho mỗi review
- review_title: Short review - Tiêu đề ngắn của review
- review_content: Long review - Nội dung đầy đủ của review
- img_link: Image Link of the Product - Link hình ảnh của sản phẩm
- product_link: Official Website Link of the Product - Link chính thức của sản phẩm trên Amazon

2. CÂU HỎI

2.1 Câu 1: Chuẩn bị và khảo sát dữ liệu cơ bản

Yêu cầu: Thực hiện các bước chuẩn bị dữ liệu sau

1. Tải dữ liệu
   - Tải file CSV vào pandas DataFrame
   - In ra shape của dataset (số hàng, số cột)
   - Hiển thị 5 hàng đầu tiên
2. Kiểm tra thông tin cơ bản
   - Sử dụng `.info()` để kiểm tra kiểu dữ liệu của mỗi cột
   - Liệt kê tên tất cả các cột
3. Kiểm tra giá trị thiếu
   - Đếm số giá trị NULL/NaN trong mỗi cột
   - Tính phần trăm dữ liệu thiếu cho mỗi cột
4. Thống kê mô tả
   - Sử dụng `.describe()` để có cái nhìn tổng quát về dữ liệu số

- Tính giá trị min, max, mean, median, std cho các cột số chính

Hàm/Phương pháp	Mục đích	Ví dụ
`pd.read_csv()`	Nhập dữ liệu từ file CSV	`df = pd.read_csv()`
`.head(n)`	Xem n hàng đầu tiên	`df.head()`
`.tail(n)`	Xem n hàng cuối cùng	`df.tail()`
`.shape`	Kích thước (hàng, cột)	`df.shape`
`.info()`	Kiểu dữ liệu, non-null counts	`df.info()`
`.describe()`	Thống kê cơ bản (số học)	`df.describe()`
`.isnull().sum()`	Đếm missing values	`df.isnull().sum()`
`.duplicated()`	Phát hiện duplicate rows	`df.duplicated().sum()`
`.columns`	Tên các cột	`df.columns.tolist()`

2.2 Câu 2: Làm sạch và biến đổi dữ liệu

Yêu cầu:

1. Xử lý giá trị thiếu
   - Xác định các cột có nhiều giá trị NULL nhất
   - Xử lý các giá trị đó như thế nào? Giải thích lý do?
   - Xác nhận rằng không còn giá trị NULL
2. Chuyển đổi kiểu dữ liệu:
   - Cột giá (`discounted_price`, `actual_price`): chuyển từ string sang float
   - Cột `discount_percentage`: loại bỏ ký tự % và chuyển sang float.
   - Cột `rating`: đảm bảo kiểu dữ liệu là float (xử lý các giá trị không hợp lệ)
   - Cột `rating_count`: chuyển sang int
3. Tạo các cột mới
   - `discounted_price_usd`: chuyển đổi từ Rupee sang USD (tỷ giá 1 USD = 83 INR)
   - `actual_price_usd`: chuyển đổi từ Rupee sang USD
   - `discount_amount`: tính số tiền chiết khấu thực tế (`actual_price - discounted_price`)
   - `price_ratio`: tỷ lệ giá khuyến mãi / giá gốc
4. Hiển thị 5 dòng dữ liệu sau xử lý.

2.3 Câu 3: Phân tích thống kê về giá

Yêu cầu:

1. Thống kê giá cả
   - Tính mean, median, mode, std, variance của `discounted_price_usd`
   - Tính quartile (Q1, Q2, Q3) và IQR
   - Xác định outlier sử dụng phương pháp IQR
   - In số lượng sản phẩm outlier
2. Phân tích chiết khấu
   - Tính tỷ lệ chiết khấu trung bình theo toàn bộ dataset
   - Tìm sản phẩm có chiết khấu cao nhất và thấp nhất

2.6 Câu 6: Phân tích người dùng và review

Yêu cầu:

1. Thống kê người dùng
   - Đếm số lượng người dùng độc nhất (`user_id`)
   - Đếm số lượng review độc nhất (`review_id`)
   - Đếm số review trung bình trên mỗi người dùng
2. Phân tích hoạt động người dùng
   - Xác định top 10 người dùng viết nhiều review nhất
   - Tính số lượng unique products mà mỗi người dùng đã review
3. Phân tích độ dài review
   - Tính độ dài của `review_title`
   - Tính độ dài của `review_content`
   - Vẽ histogram thể hiện phân bố độ dài review
4. Tương quan review và rating
   - Kiểm tra xem review dài hơn có liên quan đến rating khác nhau không
   - Phân tích `review_title`: những từ nào xuất hiện nhiều nhất?

2.7 Câu 7: Trực quan hóa dữ liệu

Yêu cầu:

1. Top 15 category theo số lượng sản phẩm
2. Phân bố sản phẩm theo category (chỉ hiển thị top 10, category khác gom lại)
3. Vẽ correlation heatmap giữa các biến số (actual_price_usd, discounted_price_usd, discount_percentage, rating, rating_count)
4. Tạo 1 biểu đồ kết hợp subplots (2x2) thể hiện: 1) Phân bố giá, 2) Phân bố rating, 3) Category distribution, 4) Price vs Rating

2.8 Câu 8: Khám phá dữ liệu văn bản

Yêu cầu:

1. Xử lý văn bản cơ bản
   - Xóa giá trị NULL trong review_content
   - Chuyển tất cả về chữ thường (lowercase)
   - Xóa các ký tự đặc biệt và số
   - Xóa khoảng trắng thừa
2. Thống kê từ
   - Tách từ từ review_content sử dụng split()
   - Đếm từ xuất hiện nhiều nhất
   - Tạo list top 30 từ phổ biến nhất
3. Phân tích độ dài
   - Tính độ dài (số từ) của mỗi review
   - Phân tích mối quan hệ: số từ trong review vs rating
   - Tạo các nhóm dựa trên độ dài: very short ($<$ 10 từ), short (10-50), medium (50-200), long ($>$ 200)
   - Tính rating trung bình của mỗi nhóm

2.9 Câu 9*: Tổng hợp phân tích

Yêu cầu:

1. Phân tích chất lượng sản phẩm
   - Xác định top 10 sản phẩm xuất sắc: rating cao + lượt đánh giá nhiều + giá cạnh tranh
   - Xác định bottom 10 sản phẩm kém: cần cải thiện hoặc loại bỏ
   - Phân tích sản phẩm nào có rating tốt nhất nhưng giá lại cao?

2.10 Câu 10*: Tạo dashboard tổng hợp kết quả

Yêu cầu:

1. Bố cục 3x3 hoặc 4x3 chứa các biểu đồ chính (tối thiểu 8 biểu đồ). Biểu đồ bao gồm:
   - Phân bố giá
   - Phân bố rating
   - Top categories
   - Giá vs Rating scatter plot
   - Discount vs Rating scatter plot
   - Rating heatmap by category
   - Top 10 products
   - Review length distribution

Nộp bài: Chạy code bài tập trên Colab hoặc các IDE (.py), thực hiện lại demo và làm các bài tập về nhà theo yêu cầu. Nếu thực hiện trên các IDE thì nộp kèm các file code kèm theo 1 pdf kết quả chạy. Đặt tên MSSV_HoVaTen_Lab7.pdf và nộp theo deadline trên Courses.